AB-тест новой формы оплаты ЖКХ

Данные и очистка

Исходно в выборках 1504 пользователя и 2661 попытка оплаты; в итоговую выборку попали 1501 пользователь и 2 659 попыток оплаты.

В ходе анализа обнаружены проблемы с данными:

- Пользователь 1010 попал одновременно в разные группы (A и B): в листе пользователей он в группе A, а платеж 99002 с его участием помечен меткой B. Принято решение оставить пользователя, но удалить противоречивый платеж. В дальнейшем этот момент проверялся на устойчивость тестирования.
- Пользователи с ошибочным возрастом (-5 и 150) - id 9002 и 9003 - при этом у этих пользователей нет ни одной попытки оплаты, они исключены из выборки..
- Платеж 99003 без указания user_id - удален, поскольку тест рандомизируется по пользователям.
- У пользователей 9003 и 9004 - не указан/не корректно указан город - 9004 оставлен в выборке, а 9003 удален ранее..
- Пользователь 9001 не отнесен к группе тестирования - удален.
- Платеж 99001 имеет нестандартный номер и срок оплаты ниже, чем в среднем по выборке(1 минута). Однако логика воронки не нарушена, пользователь оставлен.

Анализ показывает логическую целостность воронки, время между шагами правдоподобно (медианы 1, 4 и 6 минут). Нагрузка по дням в группах схожа, явных расхождений в динамике нет.

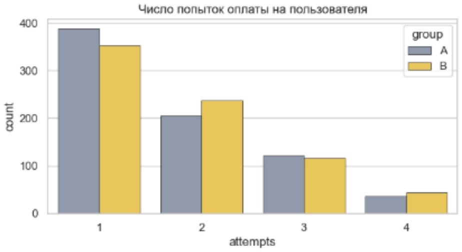

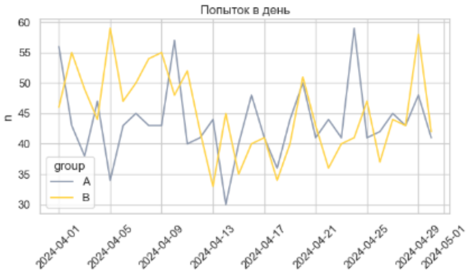

Дизайн теста

Метод: A/B тест. A - действующая форма, B - форма с автозаполнением реквизитов. Рандомизация по пользователям, единица наблюдения - попытка оплаты (от 1 до 4 на пользователя). Период 1-30 апреля 2024.

Метрики:

- основная (H1): конверсия из шага 1 (открыл форму) в шаг 4 (успешная оплата) = успешные оплаты / попытки; по ней принимается решение;
- подтверждающая (H2): доля пользователей хотя бы с одной успешной оплатой;
- диагностика механизма (H3): конверсия на шагах 1→2, 2→3, 3→4;
- проверка знаменателя (H4a): число попыток на пользователя;
- guardrail (H4b): доля неуспешных попыток, за которыми в течение 24 часов последовала новая; время на шагах (H5);
- однородность (H6): эффект по устройству, городу и неделе теста.

Основные выводы делаем по H1 - запускаем, если она показывает значимое улучшение и при этом guardrail не нарушен.

Параметры теста:

- ошибка 1 рода - 5%
- мощность 80%
- MDE - 5,4 п.п.
- размер выборки - 751/750 пользователей на группу за 30 дней.

Проверка рандомизации

SRM (критерий X2): 751 и 750 пользователей, p = 0,98 - перекоса нет. Возраст, город, устройство и период первой попытки сбалансированы (устройство, город и попытку проверяем через X2 p = 0,06, p = 0,44 и p = 0,17 соответственно; возраст через Манна-Уитни (p = 0,82), т.к. он не нормален и усечен снизу) .

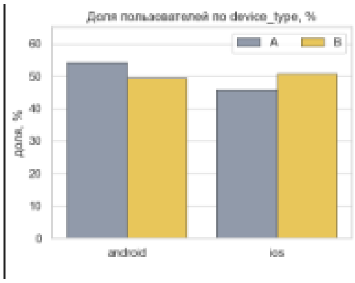

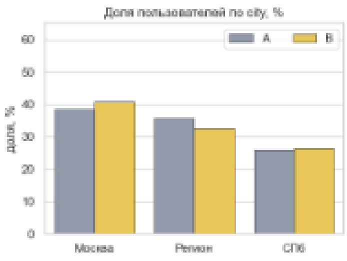

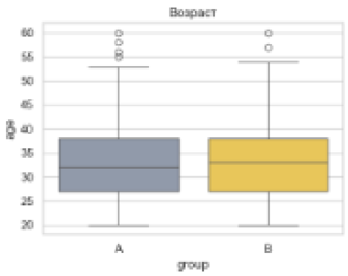

AA-тест Проверяем, что выбранный критерий не находит эффект там, где его нет. Использовались два критерия: дельта-метод с кластерами-пользователями и наивный z-тест, который считает все попытки независимыми. A/A проводился на реальных данных, 20 000 повторов в двух вариантах: метки A/B случайно перемешивались между пользователями; контрольная группа A делилась пополам (в ней воздействия нет). Доля ложных срабатываний у обоих критериев составила 4.7–5.3% при номинальных 5%.

AB-тест Эффект оценивался по основной метрике: разность конверсий считалась дельта-методом, независимой проверкой служил кластерный бутстреп (10 000 повторов).

Дополнительно проверялись: доля пользователей с ≥1 успешной оплатой (H2); конверсия на каждом шаге воронки (H3, поправка Холма); число попыток на пользователя (H4a, критерий Уэлча) и guardrail H4b; время на шагах (H5, критерий Манна–Уитни); гетерогенность эффекта по устройству, городу и неделе теста (H6, Cochran Q, поправка Холма).

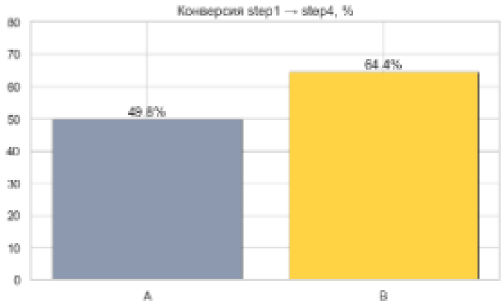

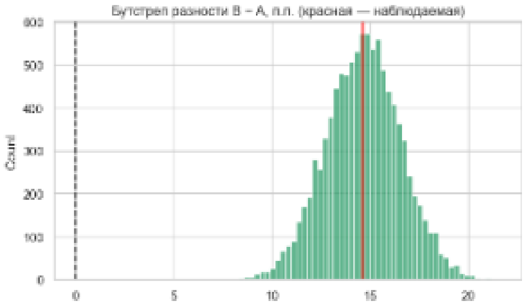

Результаты

1. Эффект значим - конверсия step1 → step4 выросла с 49.8% (A) до 64.4% (B): +14.6 п.п., (95% ДИ [10.9; 18.3], $p < 0.001$)
2. Выигрыш есть и на уровне пользователей. Доля пользователей хотя бы с одной успешной оплатой выросла с 65.7% до 80.4% (+14.8 п.п., ДИ [10.4; 19.2]).
3. Эффект есть на каждом шаге воронки. Конверсии по шагам выросли на +7.3 п.п. (step1→2), +9.0 п.п. (step2→3) и +4.7 п.п. (step3→4).. Время на шагах не изменилось (медианы 1, 4 и 6 минут).
4. Эффект однороден и не затухает. Он положителен во всех сегментах: Android +14.9, iOS +14.1, Москва +18.3, СПб +14.2, регионы +10.7 п.п. Различия между сегментами не подтверждаются ($p = 0.83$ по устройству, 0.24 по городу, 0.99 по неделе). По неделям эффект держится на уровне +13.6...+15.3 п.п. Признаков эффекта новизны за 30 дней нет.
5. Результат устойчив. Оценка эффекта составляет 14.4–15.0 п.п. во всех шести вариантах проверки.
6. Guardrail выдержан. Число попыток на пользователя в группах сопоставимо (1.74 против 1.80, $p = 0.20$). Доля быстрых повторов после неудачи в B не выше, чем в A (около 3–4%). Неудач в B стало меньше: 481 против 657.

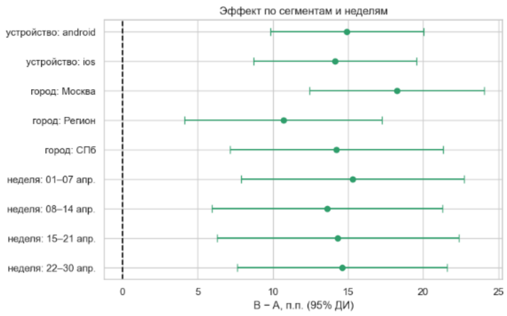

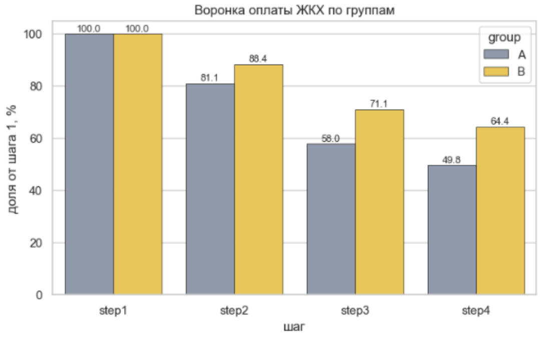

Рекомендация: запускать новую форму на всех пользователей.